

En este ejercicio, creará un modelo para predecir cancelaciones de hoteles con un clasificador binario.

Primero, cargue el conjunto de datos de Cancelaciones de hoteles.

```
features_num = [
    "lead_time", "arrival_date_week_number",
    "arrival_date_day_of_month", "stays_in_weekend_nights",
    "stays_in_week_nights", "adults", "children", "babies",
    "is_repeated_guest", "previous_cancellations",
    "previous_bookings_not_canceled", "required_car_parking_spaces",
    "total_of_special_requests", "adr",
features_cat = [
    "hotel", "arrival_date_month", "meal",
    "market_segment", "distribution_channel",
    "reserved_room_type", "deposit_type", "customer_type",
transformer_num = make_pipeline(
    SimpleImputer(strategy="constant"), # there are a few missing values
    StandardScaler(),
transformer_cat = make_pipeline(
    SimpleImputer(strategy="constant", fill_value="NA"),
    OneHotEncoder(handle_unknown='ignore'),
preprocessor = make_column_transformer(
    (transformer_num, features_num),
    (transformer_cat, features_cat),
# stratify - make sure classes are evenlly represented across splits
X_train, X_valid, y_train, y_valid = \
    train_test_split(X, y, stratify=y, train_size=0.75)
X_train = preprocessor.fit_transform(X_train)
X_valid = preprocessor.transform(X_valid)
input_shape = [X_train.shape[1]]
```

Paso1: Define model

El modelo que usaremos esta vez tendrá tanto la normalización por lotes como las capas de abandono. Para facilitar la lectura, hemos dividido el diagrama en bloques, pero puede definirlo capa por capa como de costumbre.

Defina un modelo con una arquitectura dada por este diagrama:

```
BatchNormalization(input_shape=input_shape)

Dense(256, activation='relu')

BatchNormalization()

Dropout(0.3)

Dense(256, activation='relu')

BatchNormalization()

Dropout(0.3)

Dense(1, activation='sigmoid')
```

```
Þ
     from tensorflow import keras
     from tensorflow.keras import layers
      # YOUR CODE HERE: define the model given in the diagram
     model = keras.Sequential([
          layers.BatchNormalization(input_shape=input_shape),
         layers.Dense(256, activation='relu').
         layers.BatchNormalization(),
         layers.Dropout(rate=0.3),
         layers.Dense(256, activation='relu'),
         layers.BatchNormalization(),
         layers.Dropout(rate=0.3),
         layers.Dense(1, activation='sigmoid'),
      # Check your answer
      q_1.check()
```

Correct

Paso2: Add Optimizer, Loss, and Metric

Ahora compile el modelo con el optimizador de Adam y las versiones binarias de la métrica de precisión y pérdida de entropía cruzada.

```
# YOUR CODE HERE
model.compile(
   optimizer='adam',
   loss='binary_crossentropy',
   metrics=['binary_accuracy'],
)
# Check your answer
q_2.check()
Correct
```

Paso2: Add Optimizer, Loss, and Metric

Finalmente, ejecute esta celda para entrenar el modelo y ver las curvas de aprendizaje

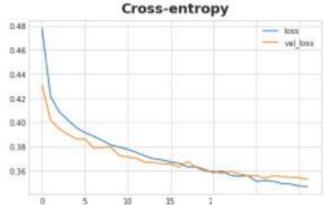
```
early_stopping = keras.callbacks.EarlyStopping(
  patience=5,
  min_delta=0.001,
  restore_best_weights=True,
history = model.fit(
  X_train, y_train,
  validation_data=(X_valid, y_valid),
  batch_size=512,
  epochs=200,
  callbacks=[early_stopping],
history_df = pd.DataFrame(history.history)
history_df.loc[:, ['loss', 'val_loss']].plot(title="Cross-entropy")
history_df.loc[:, ['binary_accuracy', 'val_binary_accuracy']].plot(title="Accuracy")
Epoch 1/200
Epoch 2/200
```

Paso2: Add Optimizer, Loss, and Metric

C---- ---

Finalmente, ejecute esta celda para entrenar el modelo y ver las curvas de aprendizaje

```
La amingadep adda, diadab daining_decondery, diadab tua_adda, diadab tua_banning_decondery, diadam
   Epoch 21/200
   175/175 [=======] - 2s 13ms/step - loss: 0.3557 - binary accuracy: 0.8353 - val loss: 0.3596 - val binary accuracy: 0.8383
   Epoch 22/200
   Epoch 23/200
   175/175 [=======] - 2s 13ms/step - loss: 0.3503 - binary accuracy: 0.8382 - val loss: 0.3593 - val binary accuracy: 0.8346
   Epoch 24/200
   175/175 [=======] - 2s 14ms/step - loss: 0.3538 - binary accuracy: 0.8357 - val loss: 0.3572 - val binary accuracy: 0.8372
   Epoch 25/200
   175/175 [=======] - 2s 14ms/step - loss: 0.3559 - binary accuracy: 0.8340 - val loss: 0.3557 - val binary accuracy: 0.8388
   Epoch 26/200
   175/175 [=======] - 2s 13ms/step - loss: 0.3495 - binary accuracy: 0.8367 - val loss: 0.3559 - val binary accuracy: 0.8373
   Epoch 27/200
   175/175 [=========] - 2s 14ms/step - loss: 0.3490 - binary accuracy: 0.8379 - val loss: 0.3536 - val binary accuracy: 0.8407
   Epoch 29/200
   Epoch 30/200
   175/175 [=======] - 2s 14ms/step - loss: 0.3473 - binary accuracy: 0.8393 - val loss: 0.3545 - val binary accuracy: 0.8390
   Epoch 31/200
   175/175 [=======] - 2s 14ms/step - loss: 0.3457 - binary accuracy: 0.8394 - val loss: 0.3539 - val binary accuracy: 0.8401
   175/175 [=======] - 2s 13ms/step - loss: 0.3442 - binary accuracy: 0.8411 - val loss: 0.3527 - val binary accuracy: 0.8392
[6]: <AxesSubplot:title={'center':'Accuracy'}>
```





Paso3: Train and evaluate

¿Qué opinas de las curvas de aprendizaje? ¿Parece que el modelo está ajustado o sobreajustado? ¿Fue la pérdida de entropía cruzada un buen sustituto de la precisión?

```
# View the solution (Run this cell to receive credit!)
q_3.check()
```

Correct:

Aunque podemos ver que la pérdida de entrenamiento continúa cayendo, la devolución de llamada de detención temprana evitó cualquier sobreajuste. Además, la precisión aumentó al mismo ritmo que disminuyó la entropía cruzada, por lo que parece que minimizar la entropía cruzada fue un buen sustituto. Considerándolo todo, ¡parece que este entrenamiento fue un éxito!